



Netflix Shows



Анализ данных по состоянию на 11.06.2017



Выполнили:

Могушкова Фатима Магомедовна, ББИ236

Татьянин Сергей Павлович, ББИ236

Мезенцев Владимир Артемьевич, ББИ236

Назин Вадим Евгеньевич, ББИ236

Григорьева Жанна Владимировна, ББИ236

Хабибулин Богдан Дмитриевич, ББИ236

Как данные определяют успех компании?

Цель: Проанализировать каталог Netflix и найти инсайты, которые помогут бизнесу принимать решения что снимать, на какую аудиторию ориентироваться и куда вкладывать деньги.

Задачи:

1. Очистить данные - разобраться с дубликатами и пропусками
2. Понять, как устроены рейтинговые группы и чем они отличаются
3. Посмотреть, какие оценки ставят пользователи и почему
4. Проследить, как менялся выпуск контента по годам
5. Составить портрет конкретного шоу на фоне всего каталога
6. Подключить внешние данные - оценки критиков, часы просмотров, страны производства
7. Найти полезные связи и зависимости
8. Дать конкретные рекомендации и предложить стратегии для бизнеса

За кулисами подготовка и очистка данных

Оптимизация: Удаление неинформативных признаков (ratingDescription, user rating size) и дубликатов, обработка пропусков

Feature Engineering: Создание признака content_type, rating_overall и нормализация оценок к 10-балльной шкале.

500 дубликатов - удаляем

пропуски в ratingLevel (33) и в user rating score (244):

- RatingLevel - описание рейтинга для группы
- User rating score - через линейную регрессию


какие признаки имеем:

- title - название шоу.
- rating - рейтинг шоу. (возрастные группы)
- ratingLevel - описание рейтинговой группы.
- ratingDescription - рейтинг шоу, закодированный числом.
- release year - год выпуска шоу.
- user rating score - оценка пользователей.
- user rating size - общий рейтинг пользователей


какие добавили:

- content_type - сериал или фильм
- rating_overall - общий рейтинг (тв + фильмы)

Дубликаты по рейтинговым группам




Количество уникальных ratingLevel для каждого rating



Анализ оценок


Какие оценки пользователи ставят чаще



Оценки смещены вправо - пик на 96–98, низкие оценки реже. Выборка, скорее всего, не случайная: Netflix показывает пользователям то, что им понравится, поэтому плохой контент просто не попадает в поле зрения. Плюс люди чаще оценивают то, что их зацепило.


Медиана: 83.5 Среднее: 81.4 Стандартное отклонение: 12.7 Минимум: 55 Максимум: 99

Какие категории больше нравятся пользователям




Взрослый контент (R, PG) - стабильно высокие оценки (медиана 87–89), узкий разброс. PG-13 - самая непредсказуемая категория (разброс 71–92). Детский контент оценивается на 10–15 баллов ниже, но это не качество - просто дети реже оставляют оценки.

Развитие Netflix по годам



- Контент с 1940-х - Netflix лицензировал уже существующий контент, выпущенный задолго до своего основания
- 2011 год - Netflix Original
- 2013 год - Netflix запустил собственное производство
- 2015 год - выход на новые рынки
- Пик 2016 - выход в 130 новых стран + 126 оригинальных проектов за год.
- Спад 2017 - не выброс, просто данные даны не за весь год, а за несколько месяцев

Распределение шоу по рейтинговым группам




- Netflix делает ставку на подростков и взрослых. TV-14 (106) и TV-MA (82) вместе занимают почти 40% каталога - это основная аудитория платформы.
- Семейное кино тоже в приоритете. PG (76) и G (53) - третье и четвёртое место, что говорит о значительном охвате семейной аудитории.
- Детский контент представлен равномерно, но скромно. TV-Y, TV-PG, TV-G, TV-Y7-FV, TV-Y7 — каждая группа по 23–36 шоу, без явных лидеров.


Вывод для бизнеса: Netflix строит каталог вокруг взрослой и подростковой аудитории - туда идёт основной объём контента. Компании, которая хочет разместить шоу на платформе, выгоднее всего попадать именно в эти категории.

Описательный портрет: Breaking Bad


Оценка пользователей



Распределение оценок



Год выпуска



Группа: TV-MA, год: 2013

Оценка: 97/100 - топ 7.5% (место №19 из 256)

Выше среднего по датасету на 16 баллов (81.4)


Выше среднего по TV-MA на 12 баллов (84.8)

Вышел в начале периода активного роста Netflix - до пика 2016 года

Гипотеза :

H0: среднее по user rating score за последние года = среднее по user rating score за давние года

H1: среднее по user rating score за последние 3 года > среднее по user rating score за давние года



Добавление новых датасетов

'netflix-rotten-tomatoes-metacritic-imdb.csv':

- IMDb Score - средняя оценка пользователей/критиков на шоу/сериал (без алгоритмов Netflix)
- Rotten Tomatoes Score - оценка профессиональных кинокритиков в процентах от 0 до 100.
Показывает долю положительных рецензий, а не среднюю оценку
- Metacritic Score - взвешенная оценка критиков по шкале от 0 до 100. В отличие от RT учитывает не просто факт положительной рецензии, а её тональность — резко положительная рецензия весит больше чем слабо положительная
- Awards Received, Awards Nominated For - кол-во полученных наград шоу/фильмом и номинированных на них

'netflix_titles.csv':

- Country - страна производства

'What_We_Watched_A_Netflix_Engagement_Report_2023Jan-Jun.csv':

- Hours Viewed - часы просмотров

data с добавленными признаками content_type и rating_overall

title	rating	ratingLevel	release year	user rating score	rating_overall	content_type	_deepnote_index_column
White Chicks	PG-13	crude and sexual humor, language and some drug content	2004	82	PG-13	Movie	0
Lucky Number Slevin	R	strong violence, sexual content and adult language	2006	nan	R	Movie	1
Grey's Anatomy	TV-14	Parents strongly cautioned. May be unsuitable for children ages 14 and under.	2016	98	PG-13	Series	2
Prison Break	TV-14	Parents strongly cautioned. May be unsuitable for children ages 14 and under.	2008	98	PG-13	Series	3
How I Met Your Mother	TV-PG	Parental guidance suggested. May not be suitable for all children.	2014	94	PG	Series	4

new_data (мердж data и 'netflix-rotten-tomatoes-metacritic-imdb.csv') по content_type
и title

[illegible]

new_data заполнили пропуски в user rating score на основе корреляции между user rating score и IMDb score

title	rating	release year	user rating score	Series or Movie	IMDb Score	Awards Received	Awards Nominated For	Hidden Gem Score	IMDb Votes
Grace and Frankie	TV-MA	2017	90	Series	08.03.2026	2	56	04.02.2026	39088
Prison Break	TV-14	2008	98	Series	08.03.2026	8	32	04.02.2026	475921
Naruto	TV-PG	2008	88	Series	08.03.2026	nan	nan	04.02.2026	71577
Master of None	TV-MA	2015	85.90628368227041	Series	08.03.2026	16	64	04.02.2026	66221
The Walking Dead	TV-MA	2015	98	Series	08.02.2026	78	223	04.01.2026	856914
The Originals	TV-14	2016	74	Series	08.02.2026	nan	13	04.01.2026	118140
Bates Motel	TV-14	2016	83	Series	08.02.2026	6	67	04.01.2026	97146
White Collar	TV-PG	2014	93	Series	08.02.2026	nan	11	04.01.2026	118747
The Fall	TV-MA	2016	61	Series	08.02.2026	8	20	04.01.2026	83814
Skins	TV-MA	2013	85.6009092966878	Series	08.02.2026	7	31	04.01.2026	74887


final_data мердж с Netflix_Engagement_Report для добавления часов просмотров (hours_viewed)											
title	rating	release year	user rating score	Series or Movie	IMDb Score	Awards Received	Awards Nominated For	Hidden Gem Score	IMDb Votes	hours_viewed	user rate score norm
Breaking Bad	TV-MA	2013	97	Series	09.05.2026	152	238	04.08.2026	1469976	505000000	09.07.2026
Death Note	TV-14	2006	77	Series	9	2	1	04.05.2026	239102	33900000	07.07.2026
The Office (U.S.)	TV-14	2012	97	Series	08.09.2026	51	193	04.05.2026	413679	341100000	09.07.2026
Friends	TV-14	2003	98	Series	08.09.2026	77	220	04.05.2026	828187	448600000	09.08.2026
Dave Chappelle	TV-MA	2017	94	Series	08.08.2026	nan	nan	5	8888	10300000	09.04.2026
Narcos	TV-MA	2016	94	Series	08.08.2026	8	18	04.04.2026	355633	195900000	09.04.2026
Black Mirror	TV-MA	2016	80	Series	08.08.2026	32	93	04.04.2026	444653	251800000	8
BoJack Horseman	TV-MA	2016	87.12778122460085	Series	08.07.2026	28	35	04.03.2026	112248	58900000	8.712778122460085
House of Cards	TV-MA	2016	91	Series	08.07.2026	34	215	04.03.2026	466163	68900000	09.01.2026
Puffin Rock	TV-Y	2016	87.12778122460085	Series	08.07.2026	2	9	9	734	10800000	8.712778122460085

создание data_with_country для добавления страны производства фильма (country)


мердж new_data и netflix_titles

title	rating	release year	user rating score	Series or Movie	IMDb Score	Awards Received	Awards Nominated For	Hidden Gem Score	IMDb Votes	country
Breaking Bad	TV-MA	2013	97	Series	09.05.2026	152	238	04.08.2026	1469976	United States
Sherlock	TV-14	2016	95	Series	09.01.2026	91	179	04.05.2026	807412	United Kingdom, United States
Death Note	TV-14	2006	77	Series	9	2	1	04.05.2026	239102	United States
The Office (U.S.)	TV-14	2012	97	Series	08.09.2026	51	193	04.05.2026	413679	United States
Friends	TV-14	2003	98	Series	08.09.2026	77	220	04.05.2026	828187	United States
Dave Chappelle	TV-MA	2017	94	Series	08.08.2026	nan	nan	5	8888	United States
Forensic Files	TV-14	2011	88	Series	08.08.2026	nan	1	7	4800	United States
Narcos	TV-MA	2016	94	Series	08.08.2026	8	18	04.04.2026	355633	United States, Colombia, Mexico
Black Mirror	TV-MA	2016	80	Series	08.08.2026	32	93	04.04.2026	444653	United Kingdom
BoJack Horseman	TV-MA	2016	nan	Series	08.07.2026	28	35	04.03.2026	112248	United States


Распределение User Rating Score




Распределение IMDb Score



Исходные данные
Спирмен = 0.412




После нормализации
Спирмен = 0.412 | Пирсон = 0.344




Топ-10 фильмов по просмотрам

Название




Рейтинги среди фильмов по просмотрам

Рейтинг




Топ-10 сериалов по просмотрам

Название




Рейтинги среди сериалов по просмотрам

Рейтинг



Топ-3 шоу по оценке в каждой рейтинговой группе




Вывод для бизнеса: в сегменте PG побеждают узнаваемые бренды, а не оригинальный контент. TV-14 и TV-MA - самые конкурентные группы с наибольшим количеством шоу и высокими оценками. Именно здесь сосредоточена основная аудитория Netflix, и именно сюда имеет смысл инвестировать в первую очередь

Взвешенный рейтинг зрителей по странам



Страны: количество шоу, наград и средняя оценка



ВЫВОДЫ

Мы проанализировали три датасета и пришли к неочевидному результату: оценки пользователей Netflix слабо связаны с рейтингом IMDb ($r \approx 0.3$). Ориентироваться только на внешние рейтинги при выборе контента неэффективно — важно понимать именно свою аудиторию.

Оценки зрителей. Самые стабильные высокие оценки получает взрослый контент TV-MA и R, а также семейное кино PG. Детский сегмент оценивается скромнее, но там побеждает анимация.

Просмотры. Фильмы берут за счёт семейной аудитории — один мультик смотрят всей семьёй и не один раз. Сериалы работают лучше во взрослом сегменте TV-14 и TV-MA: люди возвращаются сезон за сезоном.

Награды. Наибольшего признания критиков добиваются не блокбастеры, а нишевые и экспериментальные проекты.

Вывод. Оптимальная стратегия комбинированная. Взрослые сериалы и семейная анимация дают стабильные просмотры и удерживают подписчиков. Оригинальные авторские проекты приносят награды и выделяют платформу среди конкурентов. Одно без другого работает хуже.